

Distribuzioni

Vers. 1.1.0

Gianluca Mastrantonio

gianluca.mastrantonio@polito.it

1 Note introduttive

2 Distribuzioni

- Normal Multivariata (Vettori Gaussiani)
- Chi-quadro
- T di Student
- F di Fisher Snedecor

- Nel corso viene seguito il libro Casella Berger (con poche eccezioni, come la normale multivariata e la regressione multivariata) e ogni volta che finiremo un argomento metterò a quali capitoli faceva riferimento;
- Useremo il software R per fare degli esempi e chiarire con dataset alcuni concetti che useremo, ma non è chiesta la conoscenza di R per poter superare l'esame;
- Prima della lezione metterò a disposizione i codici R e le slides che useremo. Delle slides ci saranno due versioni, una pulita e una su cui scriverò durante la lezione;
- La scritta "chunk x" sulle slides indica che c'è un esempio nel file R allegato, al chunk x, con esempi o più dettagli;
- al fine di ogni sezione caricherò degli esercizi.

La notazione usata dagli statistici è un po' diversa da quella dei probablisti (e meno precisa), e se alcune cose si possono determinare dal contesto non si indicano. Alcuni esempi

- Sia la funzione di probabilità (pmf) che di densità (pdf) si indicano spesso con $f()$, dove f è la pmf se l'argomento è discreto, o la pdf se continuo, a meno che non serva fare una distinzione;
- La pmf e pdf di una variabile X , dipendente da parametri θ , si può scrivere equivalentemente come

$$f(X = x) \equiv f_X(x) \equiv f(x) \equiv f(x|\theta) \equiv f(x;\theta) \equiv f_\theta(x)$$

e varie altre permutazioni. L'importante è che dal contesto si capisca a cosa ci si riferisce;

- Se una variabile assume valori solo in un sottoinsieme di \mathbb{R} , per esempio \mathbb{R}^+ , o di un'altro spazio, non c'è bisogno di usare la funzione indicatrice per dire dove la sua densità è zero: per esempio se $X \sim G(\alpha, \beta)$, la sua densità la si indica con

$$\frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}$$

dove è implicito che vada calcolata solo su \mathbb{R}^+ .

- Il dominio dei parametri viene in generale omesso e è quello in cui la densità esiste, se è diverso viene specificato;
- Alcune distribuzioni possono essere formalizzate in modi diversi da quello che avete visto con la Siri, per esempio la Gamma può essere anche scritta come $G(\alpha, \theta)$ con densità

$$\frac{\theta^{-\alpha}}{\Gamma(\alpha)} x^{\alpha-1} e^{-\frac{x}{\theta}}$$

altri esempi sono l'esponenziale, la geometrica etc.

- Richiamiamo dei concetti delle normali univariate. Se $X \sim N(0, 1)$ (distribuita come una normale standard), la sua densità è

$$f(x) = (2\pi)^{-\frac{1}{2}} \exp\left(-\frac{x^2}{2}\right)$$

con $E(X) = 0$ e $\text{Var}(X) = 1$ e funzione caratteristica

$$\varphi_X(t) = \exp\left(-\frac{t^2}{2}\right), \forall t \in \mathbb{R}$$

- la variabile aleatorie $Y = \mu + \sigma X$, se $\sigma \neq 0$ è distribuita normalmente ($N(\mu, \sigma^2)$) con densità

$$f(y; \mu, \sigma^2) = (2\pi\sigma^2)^{-\frac{1}{2}} \exp\left(-\frac{(y - \mu)^2}{2\sigma^2}\right)$$

con $E(X) = E(\mu + \sigma X) = \mu$, $\text{Var}(X) = \text{Var}(\mu + \sigma X) = \sigma^2 \text{Var}(X) = \sigma^2$ e funzione caratteristica

$$\varphi_Y(t) = \varphi_{\mu + \sigma X}(t) = \exp(it\mu) \varphi_X(\sigma t) = \exp\left(it\mu - \frac{\sigma^2 t^2}{2}\right)$$

- Se $\sigma = 0$ la variabile Y è degenere;
- I parametri σ e $-\sigma$ danno luogo alla stessa distribuzione;
- Trasformazione lineare di una variabile normale è ancora normale. Se $Z = a + bY$ allora $Z \sim N(a + b\mu, b^2\sigma^2)$, visto che

$$Z = a + bY = a + b(\mu + \sigma X) = a + b\mu + b\sigma X = \mu^* + \sigma^* X$$

dove $\mu^* = a + b\mu$ e $\sigma^* = b\sigma$;

Potete vedere qualche esempio in **“Chunk normale”**

Consideriamo una collezione di dimensione k di variabili aleatorie normali standard $X_i \sim N(0, 1)$, con $i = 1, \dots, k$ ($X_i \stackrel{iid}{\sim} N(0, 1)$) e indichiamo con $\mathbf{X} = (X_1, X_2, \dots, X_k)^T$. La densità congiunta è

$$\begin{aligned} f(\mathbf{x}) &= \prod_{i=1}^k f(x_i) = \prod_{i=1}^k (2\pi)^{-\frac{1}{2}} \exp\left(-\frac{x_i^2}{2}\right) = \prod_{i=1}^k (2\pi)^{-\frac{1}{2}} \exp\left(-\frac{x_i^2}{2}\right) = \\ &= (2\pi)^{-\frac{k}{2}} \exp\left(-\frac{\sum_{i=1}^k x_i^2}{2}\right) = (2\pi)^{-\frac{k}{2}} \exp\left(-\frac{\mathbf{x}^T \mathbf{x}}{2}\right) \end{aligned}$$

è facile da verificare che il vettore $E(\mathbf{X})$ ha elemento i -esimo $[E(\mathbf{X})]_i = 0$ e matrice di varianza e covarianza $\text{Var}(\mathbf{X})$ con element ij pari a

$$[\text{Var}(\mathbf{X})]_{ij} = \begin{cases} 1 & \text{se } i = j \\ 0 & \text{se } i \neq j \end{cases}$$

la funzione caratteristica è

$$\varphi_{\mathbf{X}}(\mathbf{t}) = \prod_{i=1}^k \varphi_{X_i}(t_i) = \prod_{i=1}^k \exp\left(-\frac{t_i^2}{2}\right) = \exp\left(-\frac{\mathbf{t}^T \mathbf{t}}{2}\right)$$

Normale multivariate standard (e vettori Gaussiani standard)

Un vettore aleatorio \mathbf{X} a valori in \mathbb{R}^k , assolutamente continuo, si dice vettore Gaussiano standard, e si scrive $\mathbf{X} \sim N_k(\mathbf{0}, \mathbf{I}_k) \equiv N(\mathbf{0}, \mathbf{I}_k)$ se ha densità

$$f(\mathbf{x}) = (2\pi)^{-\frac{k}{2}} \exp\left(-\frac{\mathbf{x}^T \mathbf{x}}{2}\right) \forall \mathbf{x} \in \mathbb{R}^k.$$

Un vettore Gaussiano standard si dice essere distribuito come una Normale multivariata standard o, equivalentemente, come una Gaussiana multivariata standard.

Come con il caso univariato, si può generalizzare

Normale multivariata - Caso generale

Definiamo un vettore $\boldsymbol{\mu} \in \mathbb{R}^n$ e una matrice $\mathbf{A} \in m_{n \times k}(\mathbb{R})$, allora il vettore aleatorio $\mathbf{Y} = \boldsymbol{\mu} + \mathbf{A}\mathbf{X}$ è un vettore Gaussiano di dimensione n con parametri $(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, dove $\boldsymbol{\Sigma} = \mathbf{A}\mathbf{A}^T$, e si scrive come

$$\mathbf{Y} \sim N_n(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \equiv N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$$

Per costruzione $\boldsymbol{\Sigma} \in m_{n \times n}(\mathbb{R})$.

Indichiamo con μ_i l' i -esimo elemento di $\boldsymbol{\mu}$, a_{ij} il valore in posizione ij di \mathbf{A} , e con σ_{ij} il valore in posizione ij di $\boldsymbol{\Sigma}$ se $j \neq i$, mentre l'elemento in posizione ii si indica con σ_i^2 .

Abbiamo che

$$Y_i = \sum_{h=1}^k a_{ih} X_h + \mu_i$$

$$E(Y_i) = \sum_{h=1}^k a_{ih} E(X_h) + \mu_i = \mu_i$$

$$\text{Var}(Y_i) = \sum_{h=1}^k a_{ih}^2 \text{Var}(X_h) = \sum_{h=1}^k a_{ih}^2 = [\mathbf{A}\mathbf{A}^T]_{ii} = \sigma_i^2$$

$$\text{Cov}(Y_i, Y_j) = \text{Cov}\left(\sum_{h=1}^k a_{ih} X_h + \mu_i, \sum_{l=1}^k a_{jl} X_l + \mu_j\right) = \sum_{h=1}^k \sum_{l=1}^k a_{ih} a_{jl} \text{Cov}(X_h, X_l) =$$

$$\sum_{h=1}^k a_{ih} a_{jh} = [\mathbf{A}\mathbf{A}^T]_{ij} = \sigma_{ij}$$

Quindi il vettore $\boldsymbol{\mu}$ è il vettore medie e $\boldsymbol{\Sigma}$ la matrice di varianza e covarianza.

Gli stessi risultati si possono ottenere utilizzando le regole per il calcolo di medie e varianze di combinazioni lineari di vettori

$$\begin{aligned}E(\mathbf{Y}) &= \boldsymbol{\mu} + \mathbf{A}E(\mathbf{X}) = \boldsymbol{\mu} \\ \text{Var}(\mathbf{Y}) &= \mathbf{A}\text{Var}(\mathbf{X})\mathbf{A}^T = \mathbf{A}\mathbf{I}_k\mathbf{A}^T = \boldsymbol{\Sigma}\end{aligned}$$

la funzione caratteristica di \mathbf{Y} è

$$\varphi_{\mathbf{Y}}(\mathbf{t}) = \varphi_{\boldsymbol{\mu} + \mathbf{A}\mathbf{X}}(\mathbf{t}) = \exp\left(it^T\boldsymbol{\mu}\right)\varphi_{\mathbf{X}}(\mathbf{A}^T\mathbf{t}) = \exp\left(it^T\boldsymbol{\mu} - \frac{1}{2}|\mathbf{A}^T\mathbf{t}|^2\right)$$

dove possiamo scrivere

$$|\mathbf{A}^T\mathbf{t}|^2 = (\mathbf{A}^T\mathbf{t})^T(\mathbf{A}^T\mathbf{t}) = \mathbf{t}^T\mathbf{A}\mathbf{A}^T\mathbf{t} = \mathbf{t}^T\boldsymbol{\Sigma}\mathbf{t}$$

Teorema - Chiusura rispetto a trasformazioni lineari

La famiglia dei vettori gaussiani è chiusa rispetto a trasformazione lineari

Dimostrazione:

Sia $\mathbf{Y} = \boldsymbol{\mu} + \mathbf{A}\mathbf{X}$ con $\mathbf{X} \sim N_k(\mathbf{0}, \mathbf{I}_k)$, con $\boldsymbol{\mu} \in \mathbb{R}^n$ e dove $\mathbf{A} \in m_{n \times k}(\mathbb{R})$, allora $\mathbf{Y} \sim N_n(\boldsymbol{\mu}, \mathbf{A}\mathbf{A}^t)$. Introduciamo $\mathbf{b} \in \mathbb{R}^q$ e $\mathbf{B} \in m_{q \times n}(\mathbb{R})$ e definiamo la variabile $\mathbf{Z} = \mathbf{b} + \mathbf{B}\mathbf{Y}$ abbiamo che

$$\mathbf{Z} = \mathbf{b} + \mathbf{B}\mathbf{Y} = \mathbf{b} + \mathbf{B}(\boldsymbol{\mu} + \mathbf{A}\mathbf{X}) = (\mathbf{b} + \mathbf{B}\boldsymbol{\mu}) + (\mathbf{B}\mathbf{A})\mathbf{X}$$

dove $(\mathbf{b} + \mathbf{B}\boldsymbol{\mu}) \in \mathbb{R}^q$ e $(\mathbf{B}\mathbf{A}) \in m_{q \times k}(\mathbb{R})$ e quindi

$$\mathbf{Z} \sim N_q(\mathbf{b} + \mathbf{B}\boldsymbol{\mu}, \mathbf{B}\mathbf{A}\mathbf{A}^T\mathbf{B}^T)$$



Proposizione - Proprietà delle Matrice di covarianza

Se Σ è una matrice di covarianza di un vettore aleatorio \mathbf{Y} a valori in \mathbb{R}^n , allora (i) è simmetrica e (ii) semi-definita positiva

Dimostrazione:

(i) Simmetrica:

$$\sigma_{ij} = [\Sigma]_{ij} = \text{Cov}(Y_i, Y_j) = \text{Cov}(Y_j, Y_i) = [\Sigma]_{ji} = \sigma_{ji}$$

(ii) Semi-definita positiva: prendiamo un vettore $\mathbf{u} \in \mathbb{R}^n$, abbiamo che

$$\begin{aligned} \mathbf{u}^T \Sigma \mathbf{u} &= \mathbf{u}^T \text{Cov}(\mathbf{Y}) \mathbf{u} = \mathbf{u}^T \mathbb{E} \left((\mathbf{Y} - \mathbb{E}(\mathbf{Y})) (\mathbf{Y} - \mathbb{E}(\mathbf{Y}))^T \right) \mathbf{u} = \\ &= \mathbb{E} \left(\mathbf{u}^T (\mathbf{Y} - \mathbb{E}(\mathbf{Y})) (\mathbf{Y} - \mathbb{E}(\mathbf{Y}))^T \mathbf{u} \right) = \mathbb{E} \left(\left(\mathbf{u}^T \mathbf{Y} - \mathbf{u}^T \mathbb{E}(\mathbf{Y}) \right) \left(\mathbf{u}^T \mathbf{Y} - \mathbf{u}^T \mathbb{E}(\mathbf{Y}) \right)^T \right) \end{aligned}$$

dove $\mathbf{u}^T \mathbf{Y}$ è uno scalare che ha valore atteso pari a $\mathbf{u}^T \mathbf{E}(\mathbf{Y})$ e quindi

$$\mathbf{u}^T \Sigma \mathbf{u} = \text{Var}(\mathbf{u}^T \mathbf{Y}) \geq 0$$



Proposizione - Radice principale matrice simmetrica e semi-definita positiva

Se Σ è una matrice simmetrica e semi-definita positiva di dimensione $n \times n$, allora esiste una matrice \mathbf{A} simmetrica e semi-definita positiva di dimensione $n \times n$, tale per cui vale

$$\Sigma = \mathbf{A} \mathbf{A}^T = \mathbf{A}^2$$

e \mathbf{A} viene chiamata la radice principale di Σ

Se la matrice Σ è invertibile, lo è anche la sua radice principale.

Possiamo determinare le densità del vettore $\mathbf{Y} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$

Proposizione - Densità di \mathbf{Y}

Se $\boldsymbol{\Sigma}$ è invertibile, allora \mathbf{Y} è assolutamente continua e ha densità

$$(2\pi)^{-\frac{n}{2}} \det(\boldsymbol{\Sigma})^{-\frac{1}{2}} \exp \left(-\frac{(\mathbf{y} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{y} - \boldsymbol{\mu})}{2} \right)$$

Dimostrazione:

Definiamo \mathbf{A} come la radice principale di $\boldsymbol{\Sigma}$, quindi invertibile e sia

$$\mathbf{X} = \mathbf{A}^{-1}(\mathbf{Y} - \boldsymbol{\mu}) = \mathbf{A}^{-1}\mathbf{Y} - \mathbf{A}^{-1}\boldsymbol{\mu}$$

e quindi

$$\mathbf{X} \sim N_n(\mathbf{A}^{-1}\boldsymbol{\mu} - \mathbf{A}^{-1}\boldsymbol{\mu}, \mathbf{A}^{-1}\boldsymbol{\Sigma}(\mathbf{A}^{-1})^T)$$

ma $\mathbf{A}^{-1}\boldsymbol{\mu} - \mathbf{A}^{-1}\boldsymbol{\mu} = \mathbf{0}$ e $\mathbf{A}^{-1}\boldsymbol{\Sigma}(\mathbf{A}^{-1})^T = \mathbf{A}^{-1}\mathbf{A}\mathbf{A}^T(\mathbf{A}^{-1})^T = \mathbf{I}_n$

Per costruzione abbiamo $\mathbf{Y} = \boldsymbol{\mu} + \mathbf{A}\mathbf{X}$, quindi \mathbf{Y} è assolutamente continuo ($\boldsymbol{\mu} + \mathbf{A}\mathbf{X}$ è un diffeomorfismo) e usando il metodo dello Jacobiano abbiamo che la densità è

$$f_{\mathbf{Y}}(y) = \frac{f_{\mathbf{X}}(\mathbf{A}^{-1}(\mathbf{y} - \boldsymbol{\mu}))}{\det(\mathbf{A})} = \frac{(2\pi)^{-\frac{n}{2}} \exp\left(-\frac{(\mathbf{A}^{-1}(\mathbf{y} - \boldsymbol{\mu}))^T (\mathbf{A}^{-1}(\mathbf{y} - \boldsymbol{\mu}))}{2}\right)}{\det(\mathbf{A})}$$

e visto che

$$\begin{aligned} (\mathbf{A}^{-1}(\mathbf{y} - \boldsymbol{\mu}))^T (\mathbf{A}^{-1}(\mathbf{y} - \boldsymbol{\mu})) &= (\mathbf{y} - \boldsymbol{\mu})^T (\mathbf{A}^{-1})^T \mathbf{A}^{-1} (\mathbf{A}^{-1}(\mathbf{y} - \boldsymbol{\mu})) = \\ &= (\mathbf{Y} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{Y} - \boldsymbol{\mu}) \end{aligned}$$

e $\det(\boldsymbol{\Sigma}) = \det(\mathbf{A})\det(\mathbf{A}) = \det(\mathbf{A})^2$ allora

$$f_{\mathbf{Y}}(y) = (2\pi)^{-\frac{n}{2}} \det(\boldsymbol{\Sigma})^{-\frac{1}{2}} \exp\left(-\frac{(\mathbf{y} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{y} - \boldsymbol{\mu})}{2}\right)$$



Osservazioni

- Vale anche il viceversa, cioè se Σ non è invertibile, allora \mathbf{Y} non è assolutamente continua.
- se Σ non è invertibile allora \mathbf{Y} è degenere.


Esempio di una normale bivariata con media

$$\mu = \begin{pmatrix} 0 \\ 2 \end{pmatrix}$$

e matrice di covarianza

$$\Sigma = \begin{pmatrix} 1 & 0.8 \\ 0.8 & 1.2 \end{pmatrix}$$

Il plot è stata fatto con il “**Chunk normale multivariata**”.



Esercizio 1

Sia $\mathbf{X} \sim N_3(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, con $\boldsymbol{\mu} = \mathbf{0}$ e $\boldsymbol{\Sigma} = \begin{pmatrix} 2 & 1 & -1 \\ 1 & 2 & -1 \\ -1 & -1 & 1 \end{pmatrix}$ trovare la legge di

$$\mathbf{Z} = \begin{pmatrix} x_1 - x_2 \\ x_1 + x_3 \end{pmatrix}$$

Soluzione:

Possiamo scrivere $\mathbf{Z} = \mathbf{A}\mathbf{X} + \mathbf{b}$, con $\mathbf{b} = \mathbf{0}$ e $\mathbf{A} = \begin{pmatrix} 1 & -1 & 0 \\ 1 & 0 & 1 \end{pmatrix}$, quindi \mathbf{Z} è un vettore gaussiano e $\mathbf{Z} \sim N_2(\mathbf{m}, \mathbf{V})$, dove $\mathbf{m} = \mathbf{0}$ e $\mathbf{V} = \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^T = \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix}$.

Un'alternativa è calcolare direttamente i valori attesi e varianze e covarianze. □

Esercizio 2

Sia $\mathbf{X} \sim N_2(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, con $\boldsymbol{\mu} = \mathbf{0}$ e $\boldsymbol{\Sigma} = \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix}$. \mathbf{X} è un vettore gaussiano? è assolutamente continuo?

Soluzione:

la matrice $\boldsymbol{\Sigma}$ è simmetrica e definita positiva, visto che il suo determinante è 1, quindi \mathbf{X} è un vettore Gaussiano. Visto che $\boldsymbol{\Sigma}$ è invertibile (è definita positiva), allora \mathbf{X} è assolutamente continua. □

Esercizio 3

Sia $f(\mathbf{x}) = (2\pi)^{-1} 3^{-\frac{1}{2}} \exp\left(-\frac{x_1^2 + x_1 x_2 + x_2^2}{3}\right)$, $\forall \mathbf{x} \in \mathbb{R}^2$, la funzione di densità di \mathbf{X} . La variabile \mathbf{X} è $N_2(\boldsymbol{\mu}, \boldsymbol{\Sigma})$? e che valore assumono i parametri?

Soluzione:

Dobbiamo avere che $\det(\boldsymbol{\Sigma}) = 3$, e inoltre

$$-\frac{(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu})}{2} = -\frac{x_1^2 + x_1 x_2 + x_2^2}{3}.$$

Siccome non ci sono termini con gradi < 2 , allora $\boldsymbol{\mu} = \mathbf{0}$, cioè

$$(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) = (x_1 - \mu_1)^2 [\boldsymbol{\Sigma}^{-1}]_{11} + (x_2 - \mu_2)^2 [\boldsymbol{\Sigma}^{-1}]_{22} + 2(x_1 - \mu_1)(x_2 - \mu_2) [\boldsymbol{\Sigma}^{-1}]_{12}$$

e tutti i prodotti $x_1 \mu_1$, $x_2 \mu_2$, $x_2 \mu_1$ e $x_1 \mu_2$ si devono eliminare. Abbiamo anche che

$$(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) = 2 \frac{x_1^2 + x_1 x_2 + x_2^2}{3}$$

e quindi $\Sigma^{-1} = \begin{pmatrix} 2/3 & 1/3 \\ 1/3 & 2/3 \end{pmatrix}$ il cui determinante è $\frac{1}{3}$ e quindi quello di Σ è 3. La sua
 inverse è $\Sigma = \begin{pmatrix} 2 & -1 \\ -1 & 2 \end{pmatrix}$ □

Esercizio 3

Sia $\mathbf{X} \sim N_2(\mathbf{0}, \mathbf{I}_2)$ e definiamo $\mathbf{Y} = \boldsymbol{\mu} + \mathbf{A}\mathbf{X}$, con $\boldsymbol{\mu} = \mathbf{0}$ e $\mathbf{A} = \begin{pmatrix} 1 & 1 \\ 2 & 2 \end{pmatrix}$.

Determinare la natura di \mathbf{Y} .

Soluzione:

La matrice di covarianza di \mathbf{Y} è $\Sigma = \begin{pmatrix} 2 & 4 \\ 4 & 8 \end{pmatrix}$ il cui determinante è 0, quindi non invertibile e \mathbf{Y} è degenere.

Si può anche vedere dal valore della correlazione tra Y_1 e Y_2 , che è

$$\frac{[\Sigma]_{12}}{\sqrt{[\Sigma]_{11}[\Sigma]_{22}}} = \frac{4}{\sqrt{16}} = 1, \text{ quindi perfetta correlazione.}$$

Un'altro metodo è vedere come $Y_1 = X_1 + X_2$ e $Y_2 = 2X_1 + 2X_2 = 2Y_1$, e

$P(Y_1 = 2Y_2) = P(\mathbf{Y} \in r)$, con $r = \{\mathbf{y} \in \mathbb{R}^2 : y_2 = 2y_1\}$



Proposizione - Distribuzione Marginale

Se $\mathbf{X} \sim N_n(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, allora $\forall i = 1, \dots, n$ $X_i \sim N(\mu_i, \sigma_i^2)$

Soluzione:

Possiamo usare la funzione caratteristica della normale multivariata

$$\varphi_{\mathbf{X}}(\mathbf{t}) = \exp \left(i \mathbf{t}^T \boldsymbol{\mu} - \frac{1}{2} \mathbf{t}^T \boldsymbol{\Sigma} \mathbf{t} \right)$$

e, introducendo il vettore \mathbf{e}_i di lunghezza n , che assume valore 0 per tutti gli elementi tranne l' i -esimo, in cui è uno. Allora la funzione caratteristica della i -esima marginale è

$$\varphi_{X_i}(t) = \varphi_{\mathbf{X}}(\mathbf{e}_i t) = \exp \left(i (\mathbf{e}_i t)^T \boldsymbol{\mu} - \frac{1}{2} (\mathbf{e}_i t)^T \boldsymbol{\Sigma} (\mathbf{e}_i t) \right)$$

e visto che $(\mathbf{e}_i t)^T \boldsymbol{\mu} = t \mu_i$ e $(\mathbf{e}_i t)^T \boldsymbol{\Sigma} (\mathbf{e}_i t) = t^2 \sigma_i^2$, allora

$$\varphi_{X_i}(t) = \exp \left(i t \mu_i - \frac{1}{2} t^2 \sigma_i^2 \right)$$

che è la funzione caratteristica di una normale univariata di media μ_i e varianza σ_i^2 . □

fate attenzione che il viceversa non vale, cioè se X_1, \dots, X_n sono marginalmente normali, il vettore \mathbf{X} potrebbe non essere normale

Proposizione - Indipendenza

Consideriamo una v.a. $\mathbf{X} \sim N_n(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Dividiamola in blocchi come $\mathbf{X} = \begin{pmatrix} \mathbf{X}_A \\ \mathbf{X}_B \end{pmatrix}$

dove $\mathbf{X}_A \in \mathbb{R}^{n_A}$ e $\mathbf{X}_B \in \mathbb{R}^{n_B}$, e assumiamo $\boldsymbol{\mu} = \begin{pmatrix} \boldsymbol{\mu}_A \\ \boldsymbol{\mu}_B \end{pmatrix}$ e $\boldsymbol{\Sigma} = \begin{pmatrix} \boldsymbol{\Sigma}_A & \boldsymbol{\Sigma}_{AB} \\ \boldsymbol{\Sigma}_{AB}^T & \boldsymbol{\Sigma}_B \end{pmatrix}$

dove $\boldsymbol{\mu}_A$ e $\boldsymbol{\mu}_B$ sono le medie di \mathbf{X}_A e \mathbf{X}_B rispettivamente, mentre $\boldsymbol{\Sigma}_A$ è la matrice di covarianza di \mathbf{X}_A , $\boldsymbol{\Sigma}_B$ è la matrice di covarianza di \mathbf{X}_B , mentre $\boldsymbol{\Sigma}_{AB}$ la matrice di covarianza tra A e B. Allora \mathbf{X}_A è indipendente da $\mathbf{X}_B \iff \boldsymbol{\Sigma}_{AB}$ è una matrice di zeri.

Soluzione:

(i) \implies è ovvio

(ii) per \Leftarrow definiamo $\mathbf{t} = \begin{pmatrix} \mathbf{t}_A \\ \mathbf{t}_B \end{pmatrix}$ con \mathbf{t}_A e \mathbf{t}_B di lunghezza rispettivamente n_A e n_B , e prendiamo la funzione caratteristica

$$\varphi_{\mathbf{X}}(\mathbf{t}) = \exp \left(i \mathbf{t}^T \boldsymbol{\mu} - \frac{1}{2} \mathbf{t}^T \boldsymbol{\Sigma} \mathbf{t} \right) = \exp \left(i(\mathbf{t}_A^T \boldsymbol{\mu}_A + \mathbf{t}_B^T \boldsymbol{\mu}_B) + -\frac{1}{2}(\mathbf{t}_A^T \boldsymbol{\Sigma}_A \mathbf{t}_A + \mathbf{t}_B^T \boldsymbol{\Sigma}_B \mathbf{t}_B) \right)$$

che è uguale a

$$\varphi_{\mathbf{X}}(\mathbf{t}) = \exp \left(i \mathbf{t}_A^T \boldsymbol{\mu}_A + -\frac{1}{2} \mathbf{t}_A^T \boldsymbol{\Sigma}_A \mathbf{t}_A \right) \exp \left(i \mathbf{t}_B^T \boldsymbol{\mu}_B + -\frac{1}{2} \mathbf{t}_B^T \boldsymbol{\Sigma}_B \mathbf{t}_B \right) = \varphi_{\mathbf{X}_A}(\mathbf{t}_A) \varphi_{\mathbf{X}_B}(\mathbf{t}_B)$$

e quindi $\mathbf{X}_A \perp\!\!\!\perp \mathbf{X}_B$



Si può generalizzare il risultato a più di due blocchi, anche univariati.

Proposizione - Condizionamento

Consideriamo una v.a. $\mathbf{X} \sim N_n(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Dividiamola in blocchi come $\mathbf{X} = \begin{pmatrix} \mathbf{X}_A \\ \mathbf{X}_B \end{pmatrix}$ dove $\mathbf{X}_A \in \mathbb{R}^{n_A}$ e $\mathbf{X}_B \in \mathbb{R}^{n_B}$, e assumiamo $\boldsymbol{\mu} = \begin{pmatrix} \boldsymbol{\mu}_A \\ \boldsymbol{\mu}_B \end{pmatrix}$ e $\boldsymbol{\Sigma} = \begin{pmatrix} \boldsymbol{\Sigma}_A & \boldsymbol{\Sigma}_{AB} \\ \boldsymbol{\Sigma}_{BA} & \boldsymbol{\Sigma}_B \end{pmatrix}$ dove $\boldsymbol{\mu}_A$ e $\boldsymbol{\mu}_B$ sono le medie di \mathbf{X}_A e \mathbf{X}_B rispettivamente, mentre $\boldsymbol{\Sigma}_A$ è la matrice di covarianza di \mathbf{X}_A , $\boldsymbol{\Sigma}_B$ è la matrice di covarianza di \mathbf{X}_B , mentre $\boldsymbol{\Sigma}_{AB}$ la matrice di covarianza tra A e B.

Allora la distribuzione di $\mathbf{X}_A | \mathbf{X}_B = \mathbf{x}_B$ è ancora normale multivariata con

$$\boldsymbol{\mu}_{A|B} = \boldsymbol{\mu}_A + \boldsymbol{\Sigma}_{AB} \boldsymbol{\Sigma}_B^{-1} (\mathbf{x}_B - \boldsymbol{\mu}_B)$$

$$\boldsymbol{\Sigma}_{A|B} = \boldsymbol{\Sigma}_A - \boldsymbol{\Sigma}_{AB} \boldsymbol{\Sigma}_B^{-1} \boldsymbol{\Sigma}_{BA}$$

Soluzione:

Definiamo la seguente v.a. $\mathbf{Z} = \mathbf{X}_A + \mathbf{A}\mathbf{X}_B$, con $\mathbf{A} = -\boldsymbol{\Sigma}_{AB}\boldsymbol{\Sigma}_B^{-1}$ in modo tale che $\mathbf{Z} \perp \mathbf{X}_B$:

$$\text{Cov}(\mathbf{Z}, \mathbf{X}_B) = \text{Cov}(\mathbf{X}_A, \mathbf{X}_B) + \text{Cov}(\mathbf{A}\mathbf{X}_B, \mathbf{X}_B) = \boldsymbol{\Sigma}_{AB} - \boldsymbol{\Sigma}_{AB}\boldsymbol{\Sigma}_B^{-1}\boldsymbol{\Sigma}_B = \mathbf{0}$$

dove in questo caso $\mathbf{0}$ è una matrice di zeri e siccome $(\mathbf{Z}, \mathbf{X}_B)$ sono un vettore gaussiano sono anche indipendenti.

Visto che

$$\mathbf{X}_A = \mathbf{Z} - \mathbf{A}\mathbf{X}_B$$

abbiamo che $\mathbf{X}_A|\mathbf{X}_B = \mathbf{x}_B \sim \mathbf{Z} - \mathbf{A}\mathbf{x}_B$ è gaussiano con

$$\mathbb{E}(\mathbf{X}_A|\mathbf{x}_B) = \mathbb{E}(\mathbf{Z} - \mathbf{A}\mathbf{X}_B|\mathbf{x}_B) = \mathbb{E}(\mathbf{Z}|\mathbf{x}_B) - \mathbb{E}(\mathbf{A}\mathbf{X}_B|\mathbf{x}_B) = \mathbb{E}(\mathbf{Z}) - \mathbf{A}\mathbf{x}_B$$

dove $E(\mathbf{Z}) = E(\mathbf{Z}|\mathbf{x}_B)$ perchè c'è indipendenza. Allora

$$E(\mathbf{X}_A|\mathbf{x}_B) = \boldsymbol{\mu}_A - \mathbf{A}(\mathbf{x}_B - \boldsymbol{\mu}_B) = \boldsymbol{\mu}_A + \boldsymbol{\Sigma}_{AB}\boldsymbol{\Sigma}_B^{-1}(\mathbf{x}_B - \boldsymbol{\mu}_B)$$

$$\begin{aligned} \text{Var}(\mathbf{X}_A|\mathbf{x}_B) &= \text{Var}(\mathbf{Z} - \mathbf{A}\mathbf{X}_B|\mathbf{x}_B) = \text{Var}(\mathbf{Z}) = \text{Var}(\mathbf{X}_A + \mathbf{A}\mathbf{X}_B) = \\ &= \text{Var}(\mathbf{X}_A) + \mathbf{A}\text{Var}(\mathbf{X}_B)\mathbf{A}^T + \mathbf{A}\text{Cov}(\mathbf{X}_B, \mathbf{X}_A) + \text{Cov}(\mathbf{X}_A, \mathbf{X}_B)\mathbf{A}^T = \\ &= \boldsymbol{\Sigma}_A + \boldsymbol{\Sigma}_{AB}\boldsymbol{\Sigma}_B^{-1}\boldsymbol{\Sigma}_B\boldsymbol{\Sigma}_B^{-1}\boldsymbol{\Sigma}_{BA} - 2\boldsymbol{\Sigma}_{AB}\boldsymbol{\Sigma}_B^{-1}\boldsymbol{\Sigma}_{BA} = \\ &= \boldsymbol{\Sigma}_A - \boldsymbol{\Sigma}_{AB}\boldsymbol{\Sigma}_B^{-1}\boldsymbol{\Sigma}_{BA} \end{aligned}$$



Si possono riarrangiare gli elementi di \mathbf{X} per dimostrare che per qualsiasi partizione di \mathbf{X} , in \mathbf{X}_A e \mathbf{X}_B , la distribuzione di $\mathbf{X}_A|\mathbf{X}_B$ è normale con media e varianza

$$\boldsymbol{\mu}_{A|B} = \boldsymbol{\mu}_A + \boldsymbol{\Sigma}_{AB}\boldsymbol{\Sigma}_B^{-1}(\mathbf{x}_B - \boldsymbol{\mu}_B)$$

$$\boldsymbol{\Sigma}_{A|B} = \boldsymbol{\Sigma}_A - \boldsymbol{\Sigma}_{AB}\boldsymbol{\Sigma}_B^{-1}\boldsymbol{\Sigma}_{BA}$$

Alcuni esempi di distribuzione conditionate della normale multivariata si possono vedere su “**Chunk normale multivariata**”.

Esempi della distribuzione di $X|Y = y$,
con $(X, Y)^T \sim N_2(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, con


$$\boldsymbol{\mu} = \begin{pmatrix} 0 \\ 2 \end{pmatrix}$$

e matrice di covarianza

$$\boldsymbol{\Sigma} = \begin{pmatrix} 1 & 0.8 \\ 0.8 & 1.2 \end{pmatrix}$$

per vari valori di y .

Il plot è stata fatto con il “**Chunk normale multivariata**”.



Chi-quadro

Una variabile aleatoria $\mathbf{Y} \in \mathbb{R}^+$ assolutamente continua si dice essere distribuita come una chi-quadro con $n \in \mathbb{N}$ (zero escluso) gradi di libertà (gdl), $Y \sim \chi^2(n)$, se

$$f(y) = 2^{-\frac{n}{2}} \Gamma\left(\frac{n}{2}\right)^{-1} y^{\frac{n}{2}-1} \exp\left(-\frac{y}{2}\right)$$

Abbiamo che $E(Y) = n$ e $\text{Var}(Y) = 2n$.

Alcune interessanti proprietà

- Se X_1, \dots, X_n sono iid normali standard, allora $Q = \sum_{i=1}^n X_i^2 \sim \chi^2(n)$ - la chi-quadro viene definita partendo da questa relazione;

- La somma di due chi-quadro indipendenti di n_1 e n_2 gdl è una chi quadro di $n = n_1 + n_2$ gradi di libertà. La dimostrazione è molto semplice visto che

$$\sum_{i=1}^n X_i^2 \sim \chi^2(n) = \sum_{i=1}^{n_1} X_i^2 + \sum_{i=1}^{n_2} X_{i+n_1}^2$$

e $Q_1 = \sum_{i=1}^{n_1} X_i^2 \sim \chi^2(n_1)$ e $Q_2 = \sum_{i=1}^{n_2} X_{i+n_1}^2 \sim \chi^2(n_2)$, dove per costruzione $Q_1 \perp\!\!\!\perp Q_2$;


- la $\chi^2(n)$ è una $G(n/2, 2)$ (fate attenzione a come definite il secondo parametro della gamma, altrimenti è $G(n/2, 1/2)$), visto che una $G(a, b)$ ha densità

$$f(y) = b^{-a} \Gamma(a)^{-1} y^{a-1} \exp\left(-\frac{y}{b}\right)$$

- Se X_1, \dots, X_n sono indipendenti e $X_i \sim N(\mu_i, 1)$, allora $Q = \sum_{i=1}^n X_i^2$ è distribuita come una chi-quadro non centrata con n gdl e parametro di non centralità $\lambda = \sum_{i=1}^n \mu_i^2$ e si scrive $Q \sim \chi_\lambda^2(n)$.
La media del chi-quadro non centrato è $n + \lambda$ e la varianza $2(n + 2\lambda)$;
- Se $X \sim U(0, 1)$ allora $-2 \log(X) \sim \chi^2(2)$.

Chi-quadro III

Alcune densità della chi-quadro per differenti valori dei gradi di libertà (“**chunk** chi-quadro”)



T di Student

Una variabile aleatoria $\mathbf{Y} \in \mathbb{R}$ assolutamente continua si dice essere distribuita come una T di Student con $n \in \mathbb{R}^+$ gradi di libertà (gdl), $Y \sim t(n)$, se

$$f(y) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi}\Gamma\left(\frac{n}{2}\right)} \left(1 + \frac{y^2}{n}\right)^{-\frac{n+1}{2}}$$

La T di Student ha media 0 se $n > 0$, e varianza $\frac{n}{n-2}$ se $n > 2$, è infinita se $1 < n \leq 2$, altrimenti è indefinita. La distribuzione è simmetrica e unimodale.

- La distribuzione T di Student può essere definita come la distribuzione della variabile aleatoria

$$Y = \frac{Z}{\sqrt{\frac{X}{n}}}$$



dove $Z \sim N(0, 1)$, $X \sim \chi^2(n)$, e Z e X sono indipendenti.

T di Student II

- Una generalizzazione si può ottenere se $Z \sim N(\mu, 1)$, e in questo caso Y è distribuita come una T non centrata, con parametro di non centralità μ : $Y \sim t_{\mu}(n)$.
- Con n abbastanza grande (più di 80), la T di Student può essere approssimata da una normale standard.

T di Student III

Alcune densità della T di Student per differenti valori dei gradi di libertà (sinistra) e confronto con normale standard (destra) (“**chunk T di Student**”).



F di Fisher Snedecor

Una variabile aleatoria $Y \in \mathbb{R}^+$ assolutamente continua si dice essere distribuita come una F di Fisher Snedecor con $n_1 \in \mathbb{R}^+$ e $n_2 \in \mathbb{R}^+$ gradi di libertà, $Y \sim F(n_1, n_2)$, se

$$f(y) = \frac{\sqrt{\frac{(n_1 y)^{n_1} n_2^{n_2}}{(n_1 y + n_2)^{n_1 + n_2}}}}{y B\left(\frac{n_1}{2}, \frac{n_2}{2}\right)}$$

La F di Fisher Snedecor ha media $\frac{n_2}{n_2 - 2}$ se $n_2 > 2$, altrimenti è indefinita, e varianza $\frac{2n_2^2(n_1 + n_2 - 2)}{n_1(n_2 - 2)^2(n_2 - 4)}$ se $n_2 > 4$, altrimenti è indefinita.

- La distribuzione F di Fisher Snedecor può essere definita come la distribuzione della variabile aleatoria

$$Y = \frac{X_1/n_1}{X_2/n_2}$$

dove $X_1 \sim \chi^2(n_1)$, $X_2 \sim \chi^2(n_2)$, e X_1 e X_2 sono indipendenti.

- se $X \sim t(n)$, allora $X^2 \sim F(1, n)$, e $X^{-2} \sim F(n, 1)$;
- se $X \sim B(n_1/2, n_2/2)$, allora $\frac{n_2 X}{n_1(1-X)} \sim F(n_1, n_2)$.

F di Fisher Snedecor III

Alcune densità della F di Fisher Snedecor per differenti valori dei gradi di libertà (“**chunk F di Fisher Snedecor**”).

